

豆瓣电影数据分析

提出问题

- 豆瓣电影评分跟票房的关系？
- 哪个类型和国家电影比较受欢迎？
- 豆瓣电影近 20 年评分情况怎么样？

◦ ◦ ◦

理解数据

本数据集描述了近20年豆瓣电影以及其相关信息，共包含12067条数据，共10个字段，介绍下各个字段：

Title: 标题 Types: 类型 Score: 评分 Drector: 导演
Writer: 作者 Actor: 演员 Account: 票房
Country: 国家 Label: 标签 flim_version: 电影版本

导入数据

```
import pandas as pd
```

```
import numpy as np
```

```
import random
```

```
import matplotlib.pyplot as plt
```

```
data = pd.read_csv('豆瓣电影评分movie.csv',encoding='gb18030')
```

数据清洗

```
pd.isnull(data).sum()
```

发现有数据缺失

去掉缺失数据

```
data.dropna(inplace=True)
```

```
data.shape  #(11816, 10)
```

```
title          0
types          0
score          0
director       11
writer        250
actor          0
account        0
country        0
label          0
flim_version   0
dtype: int64
```

评分分布

```
#配置matplotlib中文字体, 避免标题/标签中文乱码
plt.rcParams["font.family"] = ["SimHei", "SimHei", "Heiti TC"]
plt.rcParams["axes.unicode_minus"] = False # 解决负号显示异常

# 核心统计: 统计每个评分出现的次数
score_count = data["score"].value_counts().sort_index().reset_index()
score_count.columns = ["评分(score)", "对应电影数量"] # 重命名列, 更易读

# 打印统计结果预览
print("\n==== 评分统计结果预览 =====")
print(f"\n评分范围: {score_count['评分(score)'].min()} 分 ~ {score_count['评分(score)'].max()} 分")
print(f"平均评分: {data['score'].mean():.2f} 分")
print(f"出现次数最多的评分: {score_count.loc[score_count['对应电影数量'].idxmax(), '评分(score)']} 分")
```

```
# 绘制散点图
plt.figure(figsize=(12, 6), dpi=100) # 设置画布大小和分辨率


# 绘制散点: x轴=评分, y轴=对应数量, 设置点大小、颜色、透明度
plt.scatter(
    x=score_count["评分(score)",
    y=score_count["对应电影数量"],
    s=30, # 点的大小
    color="#1f77b4", # 点的颜色
    alpha=0.8, # 透明度
    edgecolors="none" # 去掉点的边框
)

# 设置图表标题和坐标轴标签
plt.title(label: "电影评分分布散点图", fontsize=16, fontweight="bold")
plt.xlabel(xlabel: "电影评分(score)", fontsize=12)
plt.ylabel(ylabel: "对应电影数量", fontsize=12)

# 设置网格线, 提升可读性
plt.grid(axis="y", linestyle="--", alpha=0.7)

# 自动调整布局, 避免标签被截断
plt.tight_layout()

# 显示图表
plt.show()
```



评分范围: 2.1 分 ~ 9.6 分
平均评分: 6.88 分
出现次数最多的评分: 7.5 分

电影评分柱状图

```
plt.figure(figsize=(12, 6), dpi=100)


# 用序号做x位置, 避免柱子重叠
x_pos = np.arange(len(score_count))

plt.bar(
    x=x_pos,
    height=score_count["对应电影数量"],
    width=0.6,      # 合适宽度, 不挤不重叠
    color="#1f77b4",
    alpha=0.8,
    edgecolor="none"
)

plt.title(label: "电影评分分布柱状图", fontsize=16, fontweight="bold")
plt.xlabel(xlabel: "电影评分(score)", fontsize=12)
plt.ylabel(ylabel: "对应电影数量", fontsize=12)

# 设置X轴刻度范围 2.1 ~ 9.6, 间隔0.4
x_ticks = np.arange(start_or_stop: 2, stop: 10, step: 0.4)
# 把刻度标签替换成分数
plt.xticks(
    ticks=np.linspace(start: 0, len(x_pos)-1, len(x_ticks)),
    labels=np.round(x_ticks, decimals: 1)
)

plt.grid(axis="y", linestyle="--", alpha=0.7)
plt.tight_layout()
plt.show()
```



评分与票房量


```
#绘制评分和票房数散点图
plt.figure(figsize=(12, 6), dpi=100) # 设置画布大小和分辨率

# 绘制散点: x轴=评分, y轴=对应数量, 设置点大小、颜色、透明度
plt.scatter(
    x=data['score'],
    y=data['account'],
    s=30, # 点的大小
    color="#1f77b4", # 点的颜色
    alpha=0.8, # 透明度
    edgecolors="none" # 去掉点的边框
)

plt.title(label: "电影评分与票房", fontsize=16, fontweight="bold")
plt.xlabel(xlabel: "电影评分", fontsize=12)
plt.ylabel(ylabel: "票房", fontsize=12)

# 设置网格线, 提升可读性
plt.grid(axis="y", linestyle="--", alpha=0.7)


# 自动调整布局, 避免标签被截断
plt.tight_layout()
plt.show()
```



评分占比图


```
#绘制评分占比饼图
l1=len(data[data['score']>8.0])
l2 = len(data[data['score'].between(6.0, 8.0)])
l3=len(data[data['score']<6.0])
plt.figure(figsize=(9,13))
labels=['高分','中等','低分']
sizes=[l1,l2,l3] #每块值
colors=['red','yellow','green']
explode=(0,0,0)
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus']=False
patches,text1,text2=plt.pie(sizes,
                             explode=explode,
                             labels=labels,
                             colors=colors,
                             autopct='%3.2f%%',
                             shadow=False,
                             startangle=90,
                             pctdistance=0.6)

plt.axis('equal')
plt.title('评分占比图')
plt.legend()
plt.show()
```




电影地区前十柱状图

```
#绘制电影地区前十柱状图
d2=data['country'].value_counts()
d2=d2.head(10)
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus']=False
d2.plot.bar(figsize=(10,8),title='电影地区前十')
plt.xticks(rotation=0)
plt.xlabel("上映地区")
plt.ylabel("电影数量")
plt.show()
```




电影类型前十柱状图

```
#绘制电影类型前十柱状图
d2=data['types'].value_counts()
d2=d2.head(10)
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus']=False
d2.plot.bar(figsize=(8,8),title='电影类型前十')
plt.xticks(rotation=25)
plt.xlabel("电影类型")
plt.ylabel("电影数量")
plt.show()
```




评分箱线图

```
# 创建箱线图
plt.figure(figsize=(8, 6))
plt.boxplot(score_data, labels=['评分'])
# 添加标题和标签
plt.title('评分箱线图')
plt.ylabel('分数')
plt.show()
```




利用tkinter库进行简单GUI编程


用到了：
Label,
Button,
Combobox



电影评分分布散点图



电影类型前10



电影评分分布柱状图

